

Práctica 4 - People tracking (Kalman filter)

Nombre estudiante: *Alberto Mur López*

Curso: *Sistemas inteligentes*

Docente: *Rubén Martínez*

Fecha de entrega: *December 24, 2023*

INTRODUCCIÓN

En esta práctica utilizaremos un filtro de Kalman para realizar el seguimiento de una persona o varias personas dadas una serie de observaciones.

MODELO

Dibuja el modelo gráfico




Figure 1: Modelo de gráfico

Tanto el modelo dinámico como el de observaciones, son lineales. Escribirlos en la forma $x_{t+1} = Ax_t + B\epsilon$ y $y_t = Cx_t$.

De las ecuaciones del modelo dinámico obtenemos las siguientes ecuaciones:

$$x_{t+1} = \underbrace{\begin{bmatrix} 1 & 0 & \Delta_t & 0 \\ 0 & 1 & 0 & \Delta_t \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \end{bmatrix}}_A x_t + \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}}_B \epsilon \quad (1)$$

$$y_t = \underbrace{\begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}}_C x_t \quad (2)$$

Siendo A la matriz de transición de estado B la matriz que da forma al ruido del proceso, y C la matriz de estado a medida.

FILTRO DE KALMAN

Write the Kalman Filter equations.

Predicción

$$\mu_{t|t-1} = A\mu_{t-1} \quad (3)$$

$$\Sigma_{t|t-1} = A\Sigma_{t-1}A^T + BQB^T \quad (4)$$

Siendo Q la matriz de covarianzas del ruido del proceso $\epsilon_{\dot{x}}$.

$$Q = \begin{bmatrix} \sigma_{\epsilon_{\dot{u}}}^2 & 0 \\ 0 & \sigma_{\epsilon_{\dot{v}}}^2 \end{bmatrix} \quad (5)$$

Actualización

$$\mu_{t|t} = \mu_{t|t-1} + K_t r_t \quad (6)$$

$$\Sigma_{t|t} = (I - K_t C) \Sigma_{t|t-1} \quad (7)$$

Siendo K_t la ganancia del filtro de Kalman.

$$K_t = \Sigma_{t|t-1} C^T S^{-1} \quad (8)$$

Siendo S la covarianza residual.

$$S_t = C \Sigma_{t|t-1} C^T + R \quad (9)$$

Y siendo R la matriz de covarianzas de las medidas (δ)

$$R = \begin{bmatrix} \sigma_{\delta_u}^2 & 0 \\ 0 & \sigma_{\delta_v}^2 \end{bmatrix} \quad (10)$$

Provee una estimación razonable de la desviación estándar de los ruidos de aceleración y medida.

El ajuste de dichos parámetros se ha realizado de forma manual. Variando dichos parámetros conseguimos dar mayor o menor relevancia a las estimaciones o a las observaciones respectivamente.

En nuestro caso hemos elegido una desviación estándar para el ruido de medidas de $\sqrt{100}$ en ambos ejes y una desviación estándar de $\sqrt{0.7}$ para el ruido de aceleración.

Provee una inicialización razonable para la matriz de covarianzas de estado.

En nuestro caso no nos hemos complicado y hemos inicializado la matriz a 0.

EJECUCIÓN

En la figura 2 se puede visualizar el filtro de Kalman diseñado en funcionamiento. Por un lado, en la figura 2a la detección del sensor (cruz en rojo) junto con la estimación en verde y la actualización en azul. Podemos observar como con la actualización mejoramos la precisión de nuestra estimación. Por otro lado en la figura 2b podemos observar como al perder la medida de nuestro sensor, el filtro es capaz de seguir al objetivo, eso sí aumentando su área de incertidumbre.

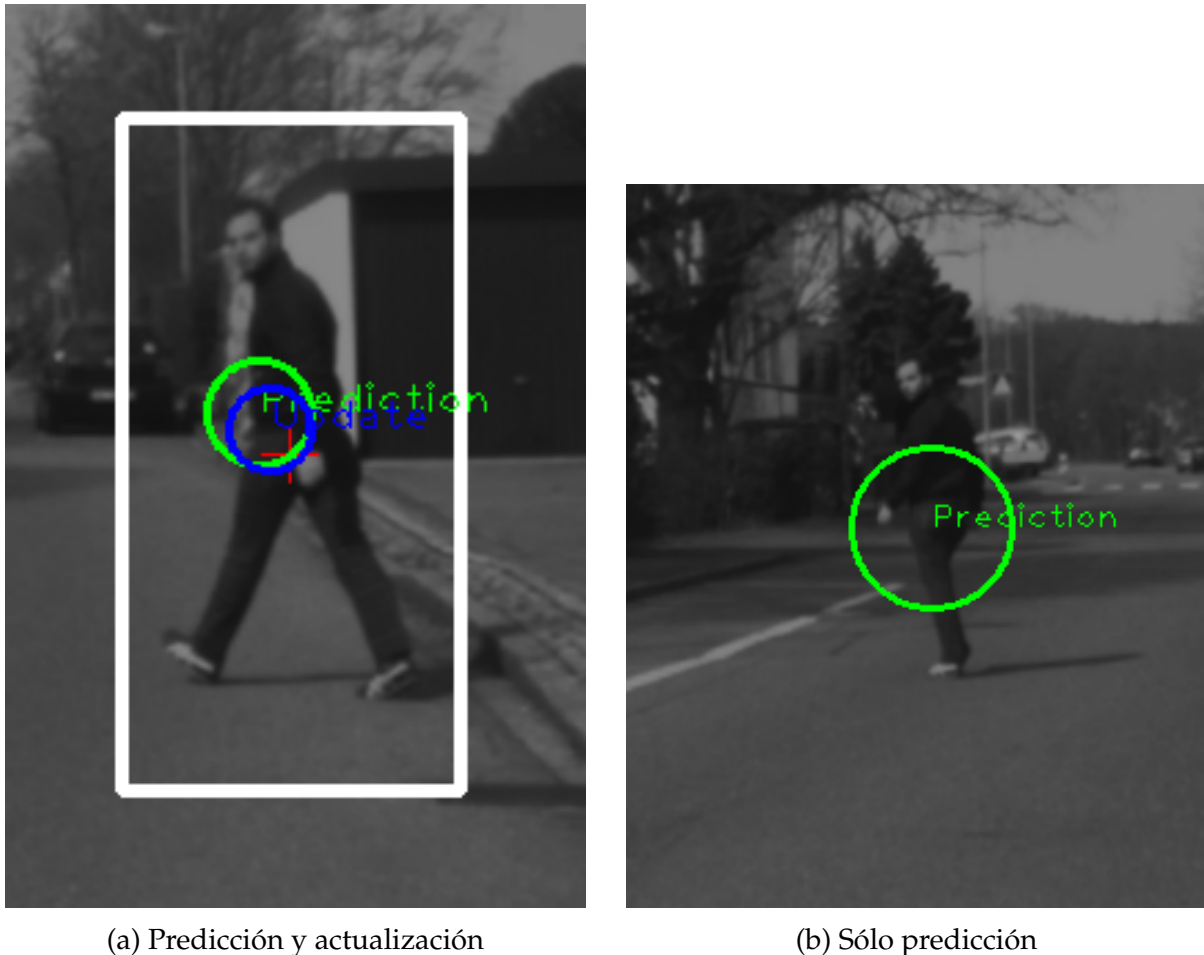


Figure 2: Ejecución de un filtro de Kalman

En la figura 3 encontramos otros dos escenarios. Primero, en la figura 3b el sensor ha vuelto a localizar el objetivo. Con la nueva medida, al realizar la actualización reducimos ampliamente el área de incertidumbre. Por último, cuando el sensor ya no es capaz de detectar al objetivo (figura 3b), el área de incertidumbre crece indefinidamente. Por ello, tras 50 observaciones fallidas del sensor damos por perdido al objetivo.

SEGUIMIENTO MÚLTIPLE

También se ha incluido soporte para seguimiento de múltiples detecciones. El reto en este escenario ha sido construir una estructura de datos que soporte la identificación y la asociación entre las detecciones entregadas por el HOGDescriptor en sucesivas iteraciones.

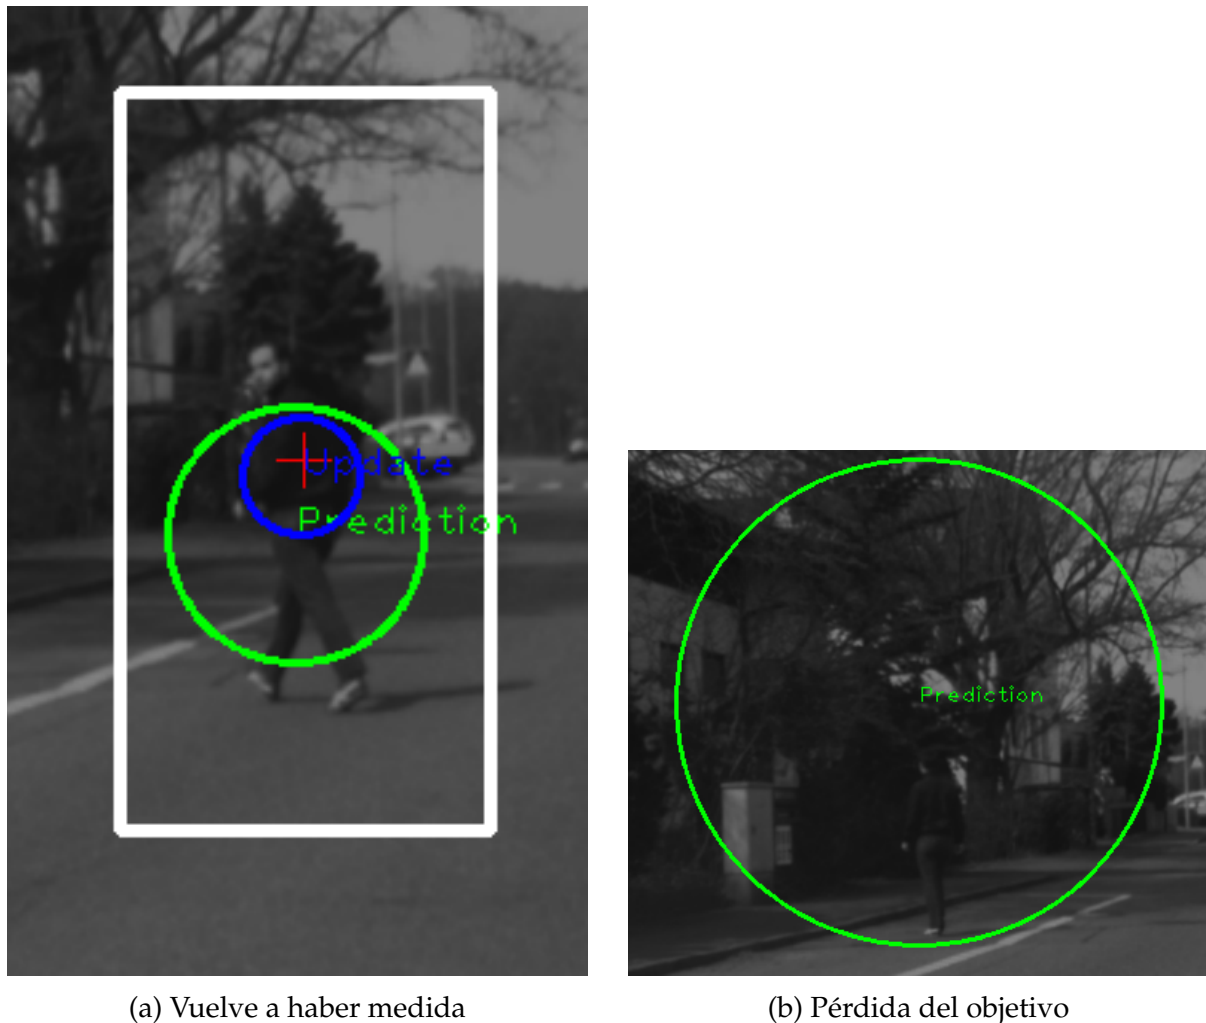


Figure 3: Ejecución de un filtro de Kalman

Se ha creado una clase que instancia un filtro de Kalman y una clase que da soporte a la detección, manteniendo el estado de la misma.

Además también se ha incluido un algoritmo de supresión no máxima para filtrar posibles objetos duplicados que se solapen.

Finalmente por cada rectángulo, se calcula la distancia de Mahalanobis para cada detección y se verifica que la distancia dicha distancia entre el centro del rectángulo y la predicción sea menor a un umbral definido dado por una distribución chi cuadrado en dos dimensiones para 0.95. De todas las posibles asociaciones nos quedamos con la menor. Un ejemplo de ejecución se puede ver en la figura 4.

1 CONCLUSION

Con esta práctica hemos podido experimentar con el algoritmo de filtro de Kalman para la estimación y predicción de valores dado un modelo dinámico. Hemos comprendido las implicaciones que tiene la inicialización del sistema y como afectan los valores de las desviaciones estándar de los ruidos del proceso y de las observaciones. Además cabe destacar la dificultad de calibrar el detector según el entorno o escenario,




Figure 4: Seguimiento de múltiples detecciones

para obtener unas buenas detecciones.